Второе поколение ИИ

Важна не мощь и не скорость новых ИИ, а «Не навреди»

Игорь Капустин

В написании текста участвовали ИИ: ChatGPT (OpenAI), Claude (Anthropic)

Книга-куст · версия 1.0 · DOI: 10.5281/zenodo.23257293 · CC BY 4.0

Пилот теряет сознание на перегрузке. Истребитель идёт к земле. За секунды до удара машина сама выводит его вверх, и пилот приходит в себя уже в наборе высоты. «Живой, — думает он. — Слава Богу!»

Нет, не так. Начну с другого.

Перо ускорилось

Сегодня текст возникает на экране почти без усилий. Минуту назад у меня были вопрос, несколько заметок и неясная догадка. И вот передо мной связные абзацы: начало, доводы, вывод. Можно попросить короче, строже, убедительнее. Перо ускорилось настолько, что кажется, будто легче стала вся работа. Как по мановению волшебной палочки.

Но готовый вид текста обманывает, и в этом его волшебство. Завершённость — иллюзия: фразы уже стоят на своих местах, а я ещё не знаю, выдерживает ли сказанное проверку. Форма приходит раньше, чем понимание того, что именно я собираюсь отдать другим людям. Пользу или вред?

В 1983 году Лизанн Бейнбридж описала родственную ловушку в статье «Ironies of Automation» [1]. Автоматика забирает у человека привычную работу и оставляет ему самое трудное: наблюдать за системой и вмешиваться, когда она ошибается. А навыки, нужные для такого вмешательства, без практики слабеют. Она писала о заводах и пультах управления, а не о языковых моделях. Но вопрос узнаваем: какую работу ИИ оставляет человеку и чем помогает ему её выполнить?

ИИ — «интеллектуальное расширение» человека. Он раздвигает поле того, что я могу сделать. Но с тем, что я подписываю, он оставляет меня один на один. Модели научили щедро снабжать нас словами. Но, мне кажется, этого уже недостаточно. В этом эссе я хочу порассуждать об ИИ другого качества: о таком, который, возможно, будет не только расширять ум человека, но и защищать самого человека — и тех людей, которых потом коснётся подписанный им текст.

Ножницы

Моя тревога проста: чем умнее модель, тем труднее найти ошибку в её тексте. Нелепость задерживает взгляд. Правдоподобная неточность проходит вместе с остальным текстом: верные термины, последовательное рассуждение и спокойный тон помогают ей затеряться. У новых моделей появляется некое «хамелеоновое» качество: ошибка принимает окраску верного текста.

Я называю это ножницами. Возможность быстро получить сложный текст растёт, а способность заметить в нём опасное место за ней не успевает. Это тенденция, а не математический закон. Однако сильная модель способна и облегчить проверку. Всё зависит от того, чему её учили.

В исследовании, опубликованном в Nature в 2024 году, более крупные и дообученные модели реже уклонялись от трудных вопросов и чаще давали внешне разумный, но неверный ответ [2]. Люди, проверявшие ответы, часть таких ошибок пропускали. Это не доказывает, что любая новая модель опаснее предыдущей. Но рост возможностей не делает ошибки заметнее для человека.

Ещё нагляднее это показала работа OpenAI 2024 года об играх «доказывающий — проверяющий» [3]. Когда модель учили прежде всего получать правильный ответ в математических задачах, её решения становились труднее для проверки. Люди, у которых было мало времени, ошибались при их оценке почти вдвое чаще. Специальное обучение проверяемости возвращало человеку возможность оценить решение. Значит, правильность и проверяемость — разные качества, и второе само из первого не вырастает.

Мне возразят: ошибок становится меньше. Хорошо. Но остаются те, что сохранились. Заметим ли мы их? И что случится, если пропустим? Чем шире применяют модель, тем больше людей может задеть одна такая ошибка. Редкость ошибки ещё не отвечает на вопрос о риске.

«Не навреди».

За гранью компетенции

ИИ раздвигает поле моих возможностей. Но расширение уводит дальше, чем простирается моя подготовка. Чем быстрее модель работает и чем больше данных обрабатывает, тем чаще она приносит мне материал за гранью моей профессиональной компетенции, моего опыта, моей эрудиции.

Там я остаюсь с текстом один на один. Проверить его сам я не могу: для этого у меня нет подготовки. Позвать специалиста можно не всегда и не по каждой фразе. А подпись под текстом — моя. Юридически я открыт и беззащитен. И не я один: в таком же положении люди, зачастую далёкие от ИИ.

Для меня самого это не страшно. Я пишу такие эссе в свободное время, в отпуске. Цели понимаю, границы допустимого вижу. Могу отложить текст на неделю, перечитать, открыть источник, спросить знающего человека. Опасно другое: автор, у которого этой недели нет. Врач между двумя пациентами, судья перед стопкой дел, командир, которому решение нужно к утру — или прямо сейчас. Он обращается за помощью к ИИ именно потому, что не успевает. И именно поэтому ему труднее оценить то, что он подписывает — или по чему действует, а это та же подпись. Выход за грань компетенции и нехватка времени складываются — так появляется опасность. Для автора, для других.

Мне видится справедливым, чтобы модель, которая вывела человека за пределы его компетенции, помогала ему там не ошибиться.

Болванка

Ответ машины мне удобно считать «болванкой» — заготовкой. Она может быть превосходной: в ней уже есть форма, материал, удачные решения. Но её ещё предстоит обработать, проверить и даже «попробовать на вкус».

Особенность этой заготовки я описал в эссе «Язык змеи» [4]. Гибридный текст пишут два разносущностных создателя: человек, чья речь выросла из жизни, и машина, чья речь выросла из вычисления. Они говорят будто бы на одном языке — русском, английском, китайском или бурятском, — но под одними словами у них разное. Это единство иллюзорно, и как раз в его щелях прячутся ошибки.

В совместной работе с ИИ текстовая заготовка становится «гибридной». Я добавляю сведения, убираю оговорку, переставляю вывод, прошу усилить довод. Модель вплетает мои дополнения в свой текст. На очередном проходе она может превратить предположение в утверждение. Я могу этого не заметить, потому что узнаю в тексте собственную мысль — но уже с другими связями, с изменённым смыслом.

Ошибаемся мы оба. Я способен принести неверную дату или перепутать причину со следствием. Модель способна придать моей ошибке ясность и убедительность. Бывает и наоборот: она написала осторожно и верно, а я вычеркнул слово, которое удерживало фразу в пределах доказанного. Так рождается ошибка, которую трудно приписать одной руке. Чтобы её предотвратить, важнее увидеть опасный переход, чем выяснить, кто сделал его первым. Хорошо бы, чтобы на гладкой поверхности был виден след фрезы: где изменился смысл, где исчезло условие, где вывод вышел за пределы основания.

Вот случай из работы над этим самым текстом. В черновике стояла фраза: «тот, кто подписывает, получает язык, чтобы требовать». Для машины она

гладкая: так она переложила привычный английский оборот, который значит «получает слова, чтобы требовать». А я, человек, споткнулся дважды. Кто кому отдал свой язык? И откуда в спокойном рассуждении взялось «требовать»? Ошибки крошечные и безобидные. Но устроены они так же, как опасные: фраза выглядит правильной, а для читателя значит не то, что для того, кто её написал. Я заметил их только потому, что у меня было время перечитать.

Сама проверка тоже ничего не гарантирует. В исследовании 2025 года о предвзятости подтверждения участники, поискав сведения в интернете, становились увереннее в ответах ИИ даже тогда, когда эти ответы были неверны [5]. Можно усердно проверять — и только этим укреплять исходное заблуждение. Сизифов труд наоборот: усилий много, а камень в конце катится на других. Мне нужен помощник, способный остановить и такую совместную работу — особенно в ту минуту, когда я уже доволен результатом и готов подписать: опубликовать, отправить, действовать, то есть согласиться с выводом нашего совместного, гибридного мышления.

Где текст становится действием

Есть тексты, которые можно отложить в сторону. А есть тексты, по которым начинают действовать другие люди. Такой текст я называю инструментальным: он не просто сообщает, он действует. На экране оба вида выглядят одинаково — приличные, аккуратные, красивые.

Представим заключение врача, где потерялась важная оговорка. Приговор, где предположение стало установленным обстоятельством. Школьную характеристику, где один эпизод превратился в постоянное свойство ребёнка. Приказ командира с двусмысленным условием. Государственное решение, основанное на непроверенном числе. Новость, где подозрение изложено как факт. Это мысленные примеры, а не рассказы о действительных случаях. Они показывают переход: ошибка покидает страницу и входит в чужую жизнь.

И на этом она не останавливается. Такого текста раньше не было на планете в таком количестве: он синтезируется за секунды, быстро оборачивается и легко масштабируется. Его цитируют, пересказывают, вставляют в новые документы. На нём учатся следующие модели ИИ [6]. Поэтому ошибка в гибридном тексте, похоже, заразна — и для людей, и для будущих машин.

«Не навреди».

Человек, которого касается текст, не видел нашей работы над ним. Он не знает, какую фразу написала модель, какую добавил автор и где они вместе потеряли смысл. Ему достаётся результат.

Поэтому главный рубеж я ставлю до подписи. Подпись здесь — это и публикация, и отправка, и утверждение: момент, после которого текст получает право действовать — сам становится инструментом. Опасную ошибку, по-моему, лучше всего останавливать раньше этого момента. Тогда не придётся исправлять чужую судьбу задним числом и спасать автора от последствий того, чего он не заметил.

Время принадлежит чтению

Время, сэкономленное на письме, принадлежит чтению — работе над болванкой. Для меня это правило работы: если черновик появился быстрее, освободившееся время стоит отдать пониманию и проверке. Под чтением я понимаю работу со смыслом: открыть источник, сопоставить утверждение с основанием, заметить пропущенное условие, спросить себя, что будет, если именно эта фраза неверна.

Но правило легко нарушить. Освободившееся время тут же занимает следующее задание, и ускорение письма превращается в очередь текстов, ждущих внимания. А тому, кто обратился к ИИ из-за нехватки времени, лишнего времени на чтение никто и не давал — и не даст. Поэтому, думаю, рассчитывать только на добрую волю подписанта не получится. Вероятно, помощь в проверке стоит встраивать в сам инструмент, чтобы она направляла внимание туда, где цена пропуска выше. Ошибка в подписи к шуточной картинке и ошибка в основании врачебного решения требуют разного внимания и разной ответственности.

Не навреди

Врачи знают это правило с первого курса: прежде всего — «не навреди!». Мне видится, что его можно принести и в работу с гибридным текстом.

Слово «безвредный» в мире ИИ уже занято. С 2021 года известна формула «полезный, честный, безвредный» [7]. Она касается того, чтобы модель не вредила своими ответами: не выдавала опасного содержания, не давала вредных советов, честно говорила о своей неуверенности. Этому модели уже учат. Я говорю о другом предмете — о совместной работе: о том, чтобы модель помогала обнаружить незаметную ошибку — свою и мою — до того, как текст коснётся людей.

Как мне это видится, такая модель смотрит на весь гибридный текст: машинное начало, человеческие дополнения, совместные переделки. Её учат замечать неверное основание, потерянную оговорку, противоречие между частями текста. Замечать, когда правка — моя или машины — испортила верное утверждение. Показывать, какой вывод не следует из приведённых данных и каких сведений не хватает для проверки. Опасные места выделяются прямо в тексте — шрифтом, цветом, а в будущем, может быть, и

рельефом, — а рядом стоят источник, точное место расхождения и возможное последствие ошибки.

Общая приписка «ИИ может ошибаться» — это для отвода глаз, для галочки; этой работы она не выполняет. Просьба «перепроверь себя» тоже не заменяет специального обучения. Здесь, по-видимому, нужна особая, «прокачанная» способность ИИ — новое его качество, которое проявляется устойчиво и подтверждается результатами совместной работы.

Мне кажется разумным подписывать результат тогда, когда человек увидел и разобрал все места совместной гибридной работы, отмеченные как опасные. «Разобрать» — значит проверить основание, исправить текст, уточнить сведения или обоснованно отвергнуть предупреждение. Одного нажатия «ознакомлен», думаю, мало: это тот самый «человеческий фактор», которым потом объясняют аварии. При этом отсутствие отметок не означает отсутствия ошибок: проверяющая модель тоже ограничена. Я не обещаю безошибочности. Мне хотелось бы, чтобы опасные ошибки реже проходили через нашу совместную работу к другим людям. Реже — а в будущем, может быть, и вовсе не проходили: чтобы специально обученный ИИ поглощал «гибридные ошибки» целиком.

У этой работы уже есть предшественники, и я не объявляю её своим изобретением. В 2024 году OpenAI представила CriticGPT — модель, обученную находить ошибки в программном коде, написанном другой моделью [8]. Разборы, сделанные человеком вместе с CriticGPT, предпочитали разборам без такой помощи более чем в 60% сравнений. Авторы честно признают, что модель-критик и сама иногда выдумывает ошибки. В 2026 году в статье Thomson Reuters Institute прозвучала формула, близкая к моей: «Если не можешь проверить, не можешь подписать» [9]. Функция Verify в их юридическом помощнике показывает каждое утверждение отчёта рядом с фрагментами источников. Принцип помощи до подписи уже существует. Новым я считаю другое — критерий, о котором речь ниже.

Пилот должен вернуться!

Теперь вернусь к пилоту, с которого я начал и на котором себя оборвал. Боевой самолёт способен на многое: огневая мощь, выбор целей, манёвр на предельных углах атаки, уход от удара. Но главное в другом: пилот должен выполнить задание и вернуться на родной аэродром. Машина выдержит перегрузку, которую не выдержит человек. Поэтому её строят так, чтобы пилот в кабине оставался в пределах своих биологических возможностей — боеспособным. Перегрузка коварна и в учебном полёте, и в бою. На пределе машина и пилот держатся на острие бритвы: между тем, на что способен самолёт, и тем, что выдержит человек — пилот, которого может захватить азарт боя.

Поэтому в авиации это уже сделано. Система управления не даёт самолёту выйти за перегрузку, опасную для пилота. Если наш пилот всё же теряет сознание и самолёт идёт к земле, автоматическая система предотвращения столкновения с землёй сама выводит его вверх: на F-16 ей приписывают спасение одиннадцати пилотов [10]. А одна из главных черт истребителей пятого поколения — слияние данных: самолёт сводит показания всех датчиков в одну понятную картину, и пилоту легче принимать решения [11].

Мне видится, что ИИ второго поколения мог бы делать для автора то же самое: «пилотировать» гибридный текст. Не допускать, чтобы материал за гранью компетенции перегрузил человека. Сводить его в обобщённую картину, которую человек способен проверить. И успеть безопасно вывести из пике до того, как ошибка коснётся земли — людей, которых затронет текст.

Заметьте: у самолётов поколение определяется не одной мощью. Оно определяется и тем, как машина работает с человеком в кабине — насколько удачен гибрид пилота и истребителя и как они выживают вместе.

Второе поколение ИИ

Поэтому я бы предложил говорить о втором поколении ИИ. Первое поколение интеллектуально расширяет человека. Второе расширяет и защищает: и автора, и людей, которых коснутся выводы гибридного текста. Защищает не юридической оговоркой и не смягчением ответственности, а профилактикой вреда. Оно не даёт ошибке пройти в инструментальный текст: в заключение врача, приговор судьи, приказ командира, государственное решение.

Модель может быть быстрой, дешёвой, сильной в рассуждениях — и всё же оставаться первым поколением по этому критерию. Второе поколение, как я его понимаю, определяют не мощь и не скорость. Его определяет умение удерживать человека на острие бритвы: дать ему всю силу машины и не навредить ни ему, ни тем, кого коснётся его подпись. Для перехода, вероятно, мало красивой панели проверки. Скорее всего, нужна специально обученная способность самой модели помогать человеку находить в совместном тексте опасные ошибки — как свои, так и ошибки самого человека.

Проверять эту способность, мне кажется, честнее всего по тому, что осталось в тексте после всей работы. Людям дают подготовить и проверить сопоставимые документы с такой помощью и без неё, а затем считают пропущенные ошибки, их тяжесть и время проверки. Учитывают и ошибки, внесённые при исправлении: слишком активный помощник способен сделать хуже. Количество предупреждений само по себе ничего не доказывает. Модель, которая отмечает всё подряд, расходует внимание, нужное для действительно опасных мест. Если люди довольны проверкой, но выпускают столько же ошибок, цель не достигнута.

Заметно меньше вредоносных ошибок доходит до людей — вот признак второго поколения, который я бы предложил. Возможно, кто-то найдёт признак точнее. Для каждой области его придётся подтверждать отдельно: успех на программном коде ещё не доказывает успеха на врачебном заключении или судебном документе. Отсюда можно предположить и третье поколение: практически полную блокаду вредоносных ошибок. Но это уже область предположений.

Зачем ставить этот вопрос?

Зачем ставить такой вопрос сейчас, когда модели и так стремительно умнеют? Думаю, потому, что улучшают обычно то, что измеряют. Сегодня модели сравнивают прежде всего по тому, как они решают задачи и пишут тексты. Если сравнивать их ещё и по тому, сколько ошибок с их помощью доходит до людей, у разработчиков, возможно, появится новая цель обучения — новый вектор: «Не навреди».

У того, кто подписывает, появляется простой вопрос к своему инструменту: где в этом тексте опасное место? Если инструмент ответить не может, это, по-видимому, инструмент первого поколения, как бы умно он ни писал. А если отвечает — проверка только начинается.

У больницы, суда, штаба, министерства появился бы критерий выбора: смотреть не только на скорость и красноречие модели, но и на то, сколько ошибок проходит с её помощью в подписанные документы.

А люди, которых касаются эти документы, получают защиту, о которой даже не узнают. Лучшая профилактика та, которую не замечают: болезнь, знаете ли, просто не случается.

Пилоту из начала этого текста повезло: в его самолёте защита уже стояла. Авторам гибридных текстов её ещё предстоит построить. Критически важно поставить этот вопрос сейчас, пока незаметные ошибки сильных моделей ещё не ушли массово в заключения, приговоры и приказы. Это тоже профилактика — на уровне всей отрасли.

Первое поколение ИИ научилось помогать нам писать красивые тексты. Второму, как мне видится, предстоит научиться помогать нам такой работой не навредить. Ошибка ещё может возникнуть у нас на столе. Задача, как я её понимаю, — успеть остановить её там: в лаборатории, в мастерской. На конвейер уходит уже чистый гибридный продукт.

Кстати, из этих рассуждений у меня сложилась открытая спецификация: что такое ИИ второго поколения и как его можно проверить [12].

Возможно, я в чём-то ошибаюсь, а вы видите это иначе. Мне интересно услышать вашу критику — и эссе, и спецификации.

Когда вы в следующий раз поставите подпись под текстом, сделанным вместе с ИИ, и доверитесь ему, — что помогло бы вам остановить ошибку до того, как она коснётся другого человека? Что? Или — кто?

Литература

[1] Bainbridge L. Ironies of Automation. Automatica. 1983. 19(6):775–779. DOI 10.1016/0005-1098(83)90046-8. Открыть источник

[2] Zhou L. et al. Larger and more instructable language models become less reliable. Nature. 2024. Vol. 634. Открыть источник

[3] Kirchner J. H. et al. Prover-Verifier Games improve legibility of LLM outputs. OpenAI, 2024. Препринт arXiv:2407.13692. Открыть источник

[4] Капустин И. Язык змеи. Глава 1 «Книги-куста», версия 1.0. 2026. DOI 10.5281/zenodo.23164404. Открыть источник

[5] Recchia G. et al. Confirmation Bias: A Challenge for Scalable Oversight. Proceedings of the AAAI Conference on Artificial Intelligence. 2026 (препринт arXiv:2507.19486, 2025). Открыть источник

[6] Капустин И. Слепые котята и воспитатели их новых моделей ИИ. Эссе. 2026. DOI 10.5281/zenodo.22924768. Открыть источник

[7] Askell A. et al. A General Language Assistant as a Laboratory for Alignment. 2021. Препринт arXiv:2112.00861. Открыть источник

[8] McAleese N. et al. LLM Critics Help Catch LLM Bugs. OpenAI, 2024. Препринт arXiv:2407.00215. Открыть источник

[9] Colbert E. If You Can’t Verify It, You Can’t Sign It. Thomson Reuters Institute. 05.05.2026. Открыть источник

[10] NASA. Resilient Autonomy Ends, Autonomy Research Ongoing. 2021 (обновлено 2023). Открыть источник

[11] Sensor Fusion: The Secret Sauce that Makes the F-35 Revolutionary. The National Interest. Открыть источник

[12] Капустин И. ИИ второго поколения: критерий гибридной выживаемости. Открытая спецификация, версия 0.2. 2026. DOI 10.5281/zenodo.23256580. Открыть источник

Текст написан с участием ИИ: ChatGPT и Claude. Дата проверки интернет-источников — 8 октября 2026 года.