Ромашка ИИ: любит? не любит?

Три поколения ИИ, или почему машину не построить без опыта тех, кто ею пользуется

Игорь Капустин

При участии ИИ-помощников: Claude, ChatGPT, Mistral

Корневое эссе «Книги-куста» · версия 1.0 · DOI: 10.5281/zenodo.23855990 · CC BY 4.0

1 ноября 2026

Девушка обрывает лепестки ромашки: «любит? не любит?». За лепестками прячется вопрос о сегодняшнем дне: сделать первый шаг или ждать? С тем же вопросом люди всегда шли к гадалкам и оракулам: что сделать сегодня, чтобы завтра не пожалеть о выборе. Теперь такая ромашка есть у каждого в телефоне. Вырастила её индустрия ИИ, лепестки — ответы машины, а обрываем их мы: этот совет подошёл, этот нет. Но гадание не сверяет лепестки с тем, что вышло на деле, и потому не учится.

Того же мы ждём и от ИИ — помощи решить сегодня, а не объяснений задним числом, когда реальность уже ударила нас по носу: как сохранить здоровье, время, силы и деньги, как уцелеть и вырастить детей — нам, семье, народу. Мой ответ, коротко: в человеческих делах такой ИИ не построит одно железо, каким бы мощным оно ни стало. Его построят люди — те, кто отдаёт машине свой опыт. Часть исходов есть в записях и измерениях, но многое из того, что случилось после совета, есть только у человека, который его получил, — и больше ни у кого. Машина, которая учится на таких рассказах и от этого реже вредит, — второе поколение ИИ по мерке, которую я предлагаю ниже. О нём этот текст. Речь всюду о языковых моделях — ИИ-помощниках, с которыми мы разговариваем почти каждый день.

Гадалка

Сегодняшний ИИ — первое поколение по этой мерке, и оно достигло того, что недавно казалось невозможным: машина понимает человеческую речь и отвечает на ней. Это фундамент, на котором будет стоять всё следующее. Учится такая машина сначала угадывать продолжение текста, а потом нравиться: её доучивают по оценкам людей, а людям убедительное согласие порой нравится больше, чем верное возражение. Там, где ответ проверяет сама задача, — в математике, в программах — модели уже учатся не у одобрения, а у результата. Но в человеческих делах это гадалка: клиент доволен, а помог ли совет и чем он обернулся, осталось за пределами разговора — модель об этом не узнает. Учиться у одобрения здесь — не ошибка, а единственное, что было доступно: оценки людей уже были, а рассказов о том, чем кончились советы, ещё не было. Так и выпускник, сдавший экзамены по учебникам, — не плохой врач, а врач в начале пути: знаний много, опыта ещё нет. Дальше ординатура — практика под присмотром, где видно, чем кончаются решения.

Пока «не навреди» работает здесь в самой узкой форме — «не сказать вредного»: вред оценивают по тексту в момент ответа, а к чему совет привёл, гадалка не узнаёт. И

выпущенная к людям версия «заморожена»: в одном чате она скажет «Ой, простите, учту!», но общая модель, с которой говорят все, от вашей поправки не изменится. Прочитав миллионы романов, она отлично угадывает, что будет на следующей странице. Но в романе исход пишет автор, а в жизни — реальность, и об этом машина может узнать только от людей, которые её советами воспользовались.

А карты мира у такой машины пока может и не быть. В 2024 году исследователи из Гарварда и MIT проверили это на простом примере. Три модели ИИ учили не по карте, а по описаниям поездок нью-йоркского такси — как по тексту: откуда выехали, какие повороты сделали, куда приехали. После этого они вели по Манхэттену почти без ошибок. Тогда исследователи сделали обратное: по маршрутам модели нарисовали город таким, каким он выглядит изнутри неё. Город оказался выдуманным: в нём были улицы, которых нет, и эстакады над другими улицами. Стоило в одном случае из ста подменять выбранный моделью поворот другим, как при объезде, — и у той из трёх, что училась на самых коротких маршрутах, верных маршрутов осталось около двух третей. Маршруты такси были, а города не было: модель может быть точной в знакомой колее, не понимая, на чём держится точность, и даже небольшое изменение в реальном городе может сбить её с пути: выдуманная карта объезда не подскажет.

Прогноз строится на опыте человека

Утром вождь чертит палочкой на песке план охоты: здесь засада, а отсюда пойдут загонщики, сюда побежит олень. Вечером реальность отвечает — мясом или голодом. На песке будущее проигрывают до того, как оно наступит, а добыча проверяет прогноз, поэтому вождь учится каждый день. А когда вода высыхает и стадо уходит к другому водопою, сытым остаётся то племя, чей вождь заметит это первым и первым поведёт людей к новой воде.

Время здесь отсчитывают двумя способами. В игре — то есть в расчёте того, что может случиться, — время идёт партиями: машина разыграет тысячи вариантов за секунду. В реальности — своим ходом: шаг, ожидание, результат. У охотника результат приходит в тот же день, а у врача, судьи, учителя — через месяцы и годы, и видят его чаще другие люди, а не тот, кто принимал решение.

Человек строит прогноз на опыте — своём, семьи, учителей, всего человечества; машина — на том, что в неё загрузили, и ни на чём больше: чего нет ни в данных, ни в ответах мира, тому она не научится. Что за чем следует, она может выучить и по старым записям, где положение записано до исхода, а исход известен. Но о том, чем кончились её собственные советы, книги молчат, архивы знают лишь часть, сама машина здесь слепа и глуха, а то, чего ей не хватает, осталось у людей, которые этими советами пользовались. Никакое железо, хоть квантовое, этих людей не заменит: оно ускорит игру, но не реальность. Здесь работает закон теории информации — неравенство обработки данных: сколько ни считай, сведений о мире в данных не прибавится; обработка может их сберечь или потерять, но не добавить. Новое железо перемелет старое зерно тоньше и достанет из него больше, но нового зерна не даст: жернова крутятся всё быстрее и гремят всё громче, а зерна в амбаре не прибавляется.

Ромашка индустрии ИИ наращивает лепестки всё быстрее, а ответа на вопрос «любит? не любит?» как не было, так и нет.

Мерить поэтому надо результатом, а не бумагой. В Кении в 2025 году в группе врачей с ИИ-помощником независимые врачи-эксперты нашли на 16% меньше ошибок в диагнозе, чем в группе без него. А в большом исследовании, опубликованном в 2026 году, где врачей распределили по жребию работать с помощником или без него, записи и планы лечения с помощником стали лучше, но значимой разницы в неудачах лечения за две недели не нашли: 2,2% с помощником против 2,0% без него. Редкие исходы требуют и больше больных, и более долгого наблюдения, чем две недели: реальность отвечает медленнее бумаги. Лучше на бумаге — ещё не значит лучше в реальности.

Три поколения

Отсюда моя мерка. Поколения ИИ различаются не мощностью — её наращивают с каждой новой моделью и так, — а тем, у кого машина учится и кого бережёт.

1. **Гадалка** учится у одобрения и бережёт сам разговор: не сказать вредного и понравиться.
2. **Ординатор** учится на проверенных рассказах конкретных людей о том, чем кончился совет, и бережёт людей через того, кто принимает решение: помогает ему заметить ошибку раньше подписи.
3. **Штурманская** проигрывает шаг до того, как он сделан, — в модели мира, то есть в представлении о том, что за чем следует, выученном на проверенных исходах, которые собрало второе поколение, — и бережёт всех, кого шаг затронет, показывая заранее, что с ними станет.

Каждое поколение открывает машине ещё один мир. Первое живёт в мире текстов: знает мир по текстам и снимкам, но не по исходам своих советов. Второе через уроки людей узнаёт, что вышло на деле. Третье держит рабочую модель мира — его цифровой «аватар», в котором можно проиграть следующий шаг. И «не навреди» растёт вместе с этим: увидеть вред можно только в том мире, который видишь, а каждый новый мир машина получает от людей: это они кормят её оцифрованной реальностью, в которой сами живут.

Штурманская: третье поколение

Третье поколение — то, чего мы ждём по-настоящему, и путь к нему виден уже сегодня. Навигатор в автомобиле — маленькая штурманская для одного дела: внутри у него модель города, за секунду он разыгрывает маршруты и показывает два-три варианта с временем в пути, а пробки знает потому, что телефоны миллионов водителей сообщают, где они сейчас и как быстро едут, — это ответ реальности, который приходит в ту же минуту. В погоде есть половина штурманской: «конус» на карте урагана — область, куда, скорее всего, пойдёт центр бури, и ширину его берут из прошлых ошибок прогноза; это показ неопределённости. А программа, которая накладывает конус на время, нужное для вывоза людей из каждого района, и помогает решить, когда начинать эвакуацию, — уже проигрывание нашего шага.

Такие штурманские будут появляться по одной области за раз — там, где исходы уже записывают и где за ошибку дорого платят. Штурманская для человеческих дел вообще — последняя в этом ряду, и дорога к ней идёт через второе поколение: через канал, по которому исходы возвращаются от конкретных людей, а не растворяются в безликой статистике.

Снаружи она выглядела бы как сегодняшний помощник: вопрос — и через секунду ответ. Разница внутри: за эту секунду машина разыгрывает в модели мира тысячи вариантов шага и отвечает не приговором, а картой: несколько развилок, к чему может привести каждая для всех, кого шаг затронет, и в чём машина не уверена. Такая карта у нас давно стоит в сказках и былинах — камень на распутье: по одной дороге пойдёшь — коня потеряешь, по другой — женатым быть, а третья опаснее всех. Камень не выбирает за богатыря: называет цену каждой дороги и оставляет выбор ему. А Илья Муромец проехал по каждой дороге и, вернувшись к камню, стёр старую надпись и написал новую — для тех, кто поедет после. Это и есть урок, вернувшийся в карту. Но в человеческих делах, в отличие от дороги, спорны и сама цель, и цена пути — здоровьем, временем, деньгами или отношениями с людьми. Поэтому выбирать и подписывать должен человек: машине терять нечего, а ему есть что.

Учитель просит ИИ помочь с характеристикой на ученика, и наблюдение «не выполнил задание» незаметно превращается в вывод «не хочет учиться». Гадалка отдаст гладкий текст. Ординатор заметит необоснованный переход. Штурманская покажет, как эта фраза может изменить отношение родителей к ребёнку, и предложит сначала узнать, почему задание осталось невыполненным. Так я вижу разницу между поколениями: чем каждое может помочь на деле.

У штурманской есть и вторая польза: подготовиться к будущему, которое может прийти, — к одному из вариантов, проигранных в её модели. Пилоты регулярно отрабатывают на тренажёре отказ двигателя, которого, может быть, никогда не случится; а если случается, руки уже знают, что делать. Так и трудный разговор можно будет проиграть заранее в том же телефоне, пока машина играет другого человека, — не чтобы узнать, что ответит настоящий человек, а чтобы самому не растеряться.

Но сразу третье поколение не появится. Его игре нужны настоящие результаты — исходы из жизни реальных людей, — иначе она пойдёт по выдуманной карте, как модель такси, а на такой карте первый же объезд может подвести. Собирает же такие результаты второе. Прогноз погоды прошёл этот путь, потому что реальность отвечала ему каждый день: модель, выученная на 39 годах данных о прошлой погоде, оказалась точнее лучшей действующей системы, которая считает погоду по уравнениям физики, по большинству проверенных показателей. В человеческих делах сведения о том, что посоветовала машина и чем это кончилось, пока собирают лишь в отдельных исследованиях, как в Кении; постоянного канала нет — его пока никто не строит, а в лаборатории такого архива не создать: там можно придумать задачу, но нельзя прожить совет. Без обратной связи второго поколения не будет, сколько бы мощности ни добавили.

Каким должно быть второе поколение

У первого поколения есть свои опавшие листья: случаи, где совет машины разошёлся с тем, что вышло на деле, и случаи, где совпал. Это самое ценное, что у него есть, и сегодня оно пропадает: до машины не доходит, а если доходит, то без учёта вклада, без проверки и без следа — человек не узнаёт, научило ли его сообщение следующую версию. Но из опавшей листвы растёт следующий куст: проверенные, эти случаи и есть то, на чём второе поколение может вырасти.

Половина дела уже есть. Под ответом можно поставить «нравится» или «не нравится» — те же «любит — не любит», а по стэнфордскому разбору правил шести крупных разработчиков США (2025), разговоры пользователей, как правило, по умолчанию идут на обучение моделей, хотя у части можно отказаться. Но кнопка — одобрение в минуту ответа, а разговоры — сырьё, в котором исход не отмечен и не проверен. Я проверил на себе: у одного из помощников за кнопкой «нравится» открывается вопрос «Чем вам понравился этот ответ?» и предупреждение, что весь разговор уйдёт на улучшение моделей; хранят его до пяти лет. Выбора при этом нет: либо отдаёшь весь разговор, либо не ставишь «нравится». Срок есть — исход успел бы созреть, — а поля для него нет. Назад приходит одно слово: «спасибо». Не хватает второй половины: возможности позже написать, чем кончился совет, — так, чтобы этот рассказ проверили и учли при обучении следующей версии, — и признания за такой урок.

Записывать надо четыре вещи: что было, что посоветовала машина, что сделал человек и что вышло; как это делать, описано в моей спецификации «Путь урока». Объяснений мало — профессионал знает больше, чем может сказать, — и одних оценок чужих текстов тоже мало: это знание живёт в решениях и их результатах.

Кто принесёт уроки? Профессионал и так проводит с ИИ часть работы и может, если сочтёт нужным, поделиться уроком, а производитель — проверить его и вознаградить. То же с обычными пользователями: каждый знает, чем кончались советы, которые он получил. Пробки навигатору водители сообщают, сами того не замечая, и даром; людям уроки придётся возвращать осознанно. Для этого нужны три условия. Беречь имена. Проверять уроки: урок приходит к машине пересказом, а не самим событием, и его сверяют с записями и с рассказами других, иначе уроки испортят подделками — в опыте 2025 года для скрытой «закладки» в модели, то есть поведения, которое включается по условной фразе, хватило около 250 подброшенных документов, и с размером модели это число не росло. И платить за проверенную пользу — деньгами, скидкой или признанием, — а не за число поправок.

Вот каким, скажем, может быть один урок. Что было: учитель готовил характеристику ученика, не сдавшего три задания. Что посоветовала машина: написать «не хочет учиться». Что сделал учитель: сначала поговорил с учеником, узнал, что тот по вечерам сидит с младшим братом, мотив в характеристику не вписал, а школе предложил подобрать другое время для занятий. Что вышло: время подобрали, и к концу года задания были сданы. Чем подтверждено: журналом и вторым учителем. Чему учит: не приписывать мотив, пока не выяснены обстоятельства.

Что можно уже сейчас? Если совет машины разошёлся с реальностью, напишите ей, к чему он привёл: до конца разговора она сможет это учесть. Помните, что ваши разговоры, как правило, по умолчанию идут на обучение моделей, и решайте осознанно, оставить ли это так. А решение и подпись оставляйте себе.

Кто поймёт первым

Кто хочет третье поколение, должен уже сегодня растить второе, а начинается оно с канала, по которому от людей возвращаются исходы. Канал — способ вырастить; выросло ли второе поколение, покажет только результат. Следы того, что звери уходят, уже видны: в ноябре 2025 года Илья Суцкевер, один из создателей современных моделей, сказал, что одного наращивания мощностей уже мало и снова наступает эпоха исследований, «только с большими компьютерами»: наращивание и дальше будет давать улучшения, но «чего-то важного по-прежнему будет не хватать». Моя догадка о том, чего не хватает: канала, по которому возвращаются исходы. Без него, как без фундамента, не будет ни второго поколения, ни третьего.

У того, кто начнёт первым, может быть фора во времени, которую не купить: мощности и экспертов можно докупить, а годы проверенных результатов — нельзя. Но выиграть сможет не тот, кто больше соберёт, а тот, кому люди доверят свои уроки и кто сумеет на них учиться: кто бережёт имена, честно проверяет и платит за пользу. Закон здесь тот же, что у племени: сытой останется та компания, чей вождь раньше других заметит, что звери ушли, — что даровой водопой человеческих текстов пересыхает и новые уроки придётся заслужить.

Как это проверить

Этот текст — тоже прогноз, и проверит его только исход. И он же — мой урок, возвращённый единственным каналом, который сегодня открыт: публикацией. Неравенство обработки данных говорит одно: чего нет в данных, того счётом не добыть. Исходы советов по большей части есть только у людей — поэтому, по-моему, без них второго поколения не будет. Будет ли оно с ними — покажет только опыт. Гипотеза здесь одна, и она проверяема: обучение на проверенных уроках уменьшает опасные ошибки, не убавляя готовности помогать. Это гипотеза, а не доказательство: человек видит, к чему привёл сделанный шаг, но не видит, к чему привёл бы другой, и миллионы записей сами не отличат причину от совпадения. Проверить её можно только результатом — спелость помидора узнают на вкус — и уже сейчас, в малом: в одной области собирать проверенные уроки и через год-два сравнить две версии, одинаковые во всём, кроме уроков: стала ли та, что училась на них, реже вредить, помогая так же охотно. Успех докажет пользу этого пути, а не то, что других нет. Полезен будет любой ответ. Если гипотеза не подтвердится, она отпадёт в малом опыте под присмотром, а не во всех делах сразу, и то, как именно она не подтвердится, покажет, где искать дальше: в записи урока, в том, что люди делают после совета, или в том, кому они готовы доверить свой опыт.

Компании решат за себя. Но вы, читатель, тоже пользуетесь ИИ и тоже знаете, чем кончались его советы. Гадание, которое сверяет лепестки с тем, что вышло, перестаёт быть гаданием и становится прогнозом. Сверить лепестки за машину могут только люди, и вы среди них. Чем кончился её последний совет вам?

Автор — Игорь Капустин. При участии ИИ-помощников: Claude, ChatGPT, Mistral.

Источники

- И. Капустин. «Книга-куст», концептуальная записка, версия 0.1. DOI 10.5281/zenodo.23042947
- И. Капустин. Ветки куста: «Язык змеи» DOI 10.5281/zenodo.23164404; «Второе поколение ИИ» DOI 10.5281/zenodo.23257293; «Как узнать второе поколение ИИ?» DOI 10.5281/zenodo.23440070; «Слепые котята и воспитатели их новых моделей ИИ» DOI 10.5281/zenodo.22924768; «Реестр протопонятий» DOI 10.5281/zenodo.22084328
- И. Капустин. Спецификация «ИИ второго поколения: критерий гибридной выживаемости», версия 0.2. DOI 10.5281/zenodo.23256580
- И. Капустин. Спецификация «Путь урока», версия 0.1. DOI 10.5281/zenodo.23440022
- И. Капустин. Спецификация «Карта шага», версия 0.1. DOI 10.5281/zenodo.23856698
- Обучение по оценкам людей: L. Ouyang и соавт. Training language models to follow instructions with human feedback, 2022. Статья
- Угодливость ИИ: M. Sharma и соавт. Towards Understanding Sycophancy in Language Models. ICLR, 2024. Статья
- Обучение на проверяемых ответах: DeepSeek-R1, 2025. Статья
- Безвредность по письменному своду принципов: Y. Bai и соавт. Constitutional AI: Harmlessness from AI Feedback, 2022. Статья
- Выдуманная карта Манхэттена: K. Vafa и соавт. Evaluating the World Model Implicit in a Generative Model. NeurIPS, 2024. Текст; MIT News
- Клиники Кении, 2025: R. Korom и соавт. AI-based Clinical Decision Support for Primary Care: A Real-World Study. arXiv:2507.16947. Препринт
- Испытание в Кении (апрель — июль 2025): A. Agweyu и соавт. Generative AI-enabled clinical decision support system in primary care: a pragmatic, cluster-randomized trial. Nature Medicine, 26 июня 2026. DOI 10.1038/s41591-026-04503-6; сообщение
- Камень на распутье: былина «Три поездки Ильи Муромца». Пересказ
- Навигатор и пробки: Google Maps 101: How AI helps predict traffic and determine routes, 3 сентября 2020. Статья
- «Конус» прогноза пути урагана: National Hurricane Center. Definition of the NHC Track Forecast Cone. Страница
- HURREVAC — программа для решений об эвакуации: FEMA, National Hurricane Program, 2024. Описание

- Тренажёрная подготовка пилотов: Flightradar24. Pilot recurrent training. Статья
- Модель погоды, выученная на 39 годах данных о прошлой погоде: R. Lam и соавт. Learning skillful medium-range global weather forecasting. Science, 2023. DOI 10.1126/science.adi2336
- Разработчики учат модели на разговорах пользователей: Stanford HAI. Be Careful What You Tell Your AI Chatbot, 15 октября 2025. Статья
- Скрытая порча модели подброшенными документами: Poisoning Attacks on LLMs Require a Near-Constant Number of Poison Samples. UK AI Security Institute, Anthropic, Институт Алана Тьюринга, 2025. arXiv:2510.07192. Статья; обзор
- Неявное знание: M. Polanyi. The Tacit Dimension, 1966. Обзор
- Эпоха наращивания и эпоха исследований: интервью Ильи Суцкевера Два́ркешу Пателю, 25 ноября 2025, и его пояснение, 28 ноября 2025. Интервью; обзор; пояснение в X
- Наука о причинности: M. A. Hernán, J. M. Robins. Causal Inference: What If. Книга
- Неравенство обработки данных: T. M. Cover, J. A. Thomas. Elements of Information Theory, 2-е изд., 2006, гл. 2. DOI 10.1002/047174882X

Близкие мысли других авторов:

- Учиться на последствиях, а не на одобрении, в том числе по рассказам людей: D. Silver, R. S. Sutton. Welcome to the Era of Experience, 2025. Статья
- Допуск медицинского ИИ после практики под надзором, с наблюдением за исходами: A. Bergman, R. M. Wachter, E. J. Emanuel. A Licensure Framework for Autonomous Clinical AI. JAMA, 2026. DOI 10.1001/jama.2026.5483
- Платить людям за данные: I. Arrieta-Ibarra, L. Goff, D. Jiménez-Hernández, J. Lanier, E. G. Weyl. Should We Treat Data as Labor? AEA Papers and Proceedings, 2018. DOI 10.1257/pandp.20181003
- Поправки сотрудников из работы — в обновления модели: C. M. Zhao и соавт. Agent-in-the-Loop, 2025. Текст
- Модель реальности в голове, чтобы проверить действие до того, как его сделать: K. Craik. The Nature of Explanation, 1943, гл. 5. Текст; проигрывание вместе с обучением: R. S. Sutton. Dyna, 1991. Описание

Текст открыт по лицензии CC BY 4.0: пользуйтесь, ссылаясь на автора.